

**IMPLEMENTASI METODE ENSEMBLE LEARNING UNTUK PREDIKSI HARGA
PROPERTI RESIDENSIAL DI WILAYAH DKI JAKARTA**



Anggota Kelompok E :

1. Abdurrahman Yusuf (K1D024058)
2. Salsabella Setya Choerunissa (K1D024060)
3. Eriani Hardianti (K1D024062)
4. Rey El Islamay (K1D024070)

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI

UNIVERSITAS JENDERAL SOEDIRMAN

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

PROGRAM STUDI STATISTIKA

PURWOKERTO

2026

BAB I

PENDAHULUAN

1.1 Latar Belakang dan Deskripsi Studi Kasus

Sektor properti residensial merupakan salah satu pilar makroekonomi nasional sekaligus instrumen investasi yang memiliki dinamika pergerakan nilai yang sangat tinggi. Di Indonesia, Daerah Khusus Ibukota (DKI) Jakarta bertindak sebagai episentrum aktivitas bisnis, pemerintahan, dan grafitasi ekonomi nasional. Daya tarik ini secara konsisten memicu arus urbanisasi skala masif yang berbenturan langsung dengan realitas geografis berupa keterbatasan suplai lahan perkotaan yang bersifat permanen (*fixed supply*). Ketidakseimbangan yang kontras antara permintaan (*demand*) dan ketersediaan (*supply*) ruang hidup inilah yang memicu fluktuasi harga properti residensial di Jakarta menjadi sangat kompleks, bervarians lebar, dan bergerak secara non-linear.

Secara konvensional, penaksiran harga jual sebuah rumah di pasar sekunder (*secondary market*) sangat bergantung pada metode penilaian manual oleh penaksir (*appraiser*) independen atau agen properti lokal yang rentan terhadap bias subjektif serta keterbatasan jangkauan sampel. Padahal, struktur pembentukan nilai ekonomi sebuah rumah merupakan hasil interaksi multi-atribut yang multidimensional. Karakteristik fisik internal properti seperti dimensi luas lahan, luas bangunan, kapasitas ruang tidur, kamar mandi, hingga kapasitas area parkir yang secara simultan berinteraksi dengan atribut eksternal spasial, yakni wilayah kota administrasi dan kecamatan tempat properti tersebut berdiri.

Studi kasus pada penelitian ini berfokus pada analisis karakteristik nilai properti residensial di seluruh wilayah DKI Jakarta. Melalui pengamatan awal terhadap fenomena pasar, sektor real estat di ibu kota memperlihatkan dispersi harga yang luar biasa ekstrem. Dinamika harga di lapangan tidak hanya mencakup hunian kelas menengah-bawah, tetapi juga aset premium bernilai ratusan miliar rupiah yang terpusat di klaster-klaster elit. Keberadaan nilai-nilai ekstrem ini, dipadukan dengan sifat hubungan non-linear antar-atribut fisik (misalnya, peningkatan luas bangunan pada wilayah tertentu tidak selalu menaikkan harga secara linier garis lurus), menuntut adanya pendekatan permodelan yang mampu menangkap pola interaksi yang kompleks secara objektif.

1.2 Urgensi dan Mengapa Masalah Ini Penting

Eksplorasi dan pemodelan prediktif harga properti memiliki urgensi yang sangat krusial, baik dari sudut pandang mikroekonomi, makroekonomi, maupun pengembangan industri teknologi properti (*PropTech*). Berikut adalah empat alasan utama mengapa penyelesaian masalah ini menjadi sangat penting:

1. Mitigasi Asimetri Informasi (*Information Asymmetry*) di Pasar Properti

Pasar properti sekunder di Indonesia sering kali dicirikan oleh ketimpangan informasi yang tajam antara penjual (*vendor*) dan pembeli (*buyer*). Ketiadaan acuan harga wajar yang objektif dan transparan membuat konsumen rentan terjebak dalam fenomena *overpricing* (terlalu mahal) yang merugikan pembeli, atau *underpricing* (terlalu murah) yang merugikan pemilik modal. Kehadiran model estimasi yang objektif berfungsi sebagai standar acuan yang memangkas bias informasi tersebut.

2. Percepatan Manajemen Risiko Kredit Lembaga Keuangan Perbankan

Dalam skema pengajuan Kredit Pemilikan Rumah (KPR), perbankan wajib melakukan penilaian agunan (*collateral valuation*) secara rigid untuk menentukan batasan nilai kredit yang aman. Proses penaksiran manual konvensional memerlukan waktu berhari-hari dan biaya operasional yang tinggi. Sistem estimasi otomatis yang memiliki tingkat akurasi tinggi dapat mentransformasikan efisiensi bisnis perbankan, mempercepat proses persetujuan kredit, sekaligus memitigasi risiko kredit macet (*Non-Performing Loan*) yang disebabkan oleh penilaian aset yang terlalu tinggi (*overvaluation*).

3. Penerapan Teori Ekonomi Spasial dan Kepadatan Lahan

Secara teoretis, nilai properti perkotaan sangat dipengaruhi oleh bagaimana bangunan tersebut memanfaatkan tapak lahannya (rasio kepadatan bangunan) serta efisiensi tata ruang internalnya. Penelitian ini menjadi penting untuk membuktikan secara ilmiah bagaimana indikator-indikator turunan dari dimensi fisik seperti tingkat kepadatan bangunan di atas tanah serta rasio kelonggaran ruang tidur, memiliki sensitivitas, dan kontribusi yang kuat dalam mengendalikan struktur nilai ekonomi rumah di kawasan padat penduduk seperti Jakarta.

4. Kebutuhan Solusi Terhadap Distribusi Data Asimetris (*Skewed Data*)

Karakteristik data properti di kota megapolitan selalu diwarnai oleh persebaran data harga yang menjulur tajam ke arah nilai tinggi akibat keberadaan rumah-rumah mewah yang harganya menjulang ekstrem dibanding rata-rata pasar. Mencoba memodelkan fenomena ini dengan pendekatan linear biasa tanpa adanya intervensi matematis khusus akan menghasilkan model yang bias dan tidak akurat. Oleh karena itu, studi ini penting untuk mendemonstrasikan bagaimana metode transformasi data dan pendekatan algoritma berbasis pohon (*tree-based paradigm*) dapat digunakan sebagai solusi teoritis untuk menjinakkan varians ekstrem tersebut.

1.3 Penentuan Jenis Masalah Machine Learning

Berdasarkan taksonomi pembelajaran terawasi (*supervised learning*), studi kasus ini secara definitif diklasifikasikan sebagai Persoalan Regresi (Regression Problem). Hal ini didasarkan pada karakteristik variabel target yang menjadi objek estimasi, yaitu harga jual properti, yang memiliki domain nilai berupa data numerik kontinu (skala rasio) dalam satuan mata uang nominal Rupiah. Secara matematis, tujuan dari pemodelan ini adalah mengonstruksi sebuah fungsi pendekatan yang mampu memetakan matriks fitur independen multipariabel (atribut fisik dan lokasi) ke dalam ruang target kontinu, dengan meminimalkan fungsi kerugian (*loss function*) di seluruh ruang observasi.

BAB II

TINJAUAN DATASET AND DATA DICTIONARY

2.1 Sumber Data

Dataset primer yang melandasi eksperimen komputasi dalam proyek akhir ini bertajuk "Jakarta House Price Dataset". Basis data tersebut dihimpun melalui platform repositori ilmiah Kaggle, di mana pengumpulan data sekundernya dilakukan secara berkala menggunakan metodologi pengumpulan data otomatis (*web scraping*) dari salah satu portal agregator pasar properti digital terbesar di Indonesia, yaitu *Rumah123.com*. Data ini merekam informasi penawaran aktif di pasar sekunder (*secondary market listings*) untuk wilayah Daerah Khusus Ibukota (DKI) Jakarta. Dengan demikian, dataset ini memiliki derajat representasi spasial dan nilai ekonomi yang sangat tinggi terhadap kondisi riil sektor real estat di lapangan.

2.2 Data Dictionary

Variabel target (output) pada dataset adalah Harga Rumah, sedangkan variabel prediktor (input) terdiri atas atribut fisik bangunan dan atribut lokasi yang diduga memengaruhi nilai properti.

Data Dictionary

No	Nama Variabel	Tipe Data	Keterangan
1	Harga	Numerik	Harga jual rumah (variabel target)
2	Luas Lahan	Numerik	Luas tanah rumah (m^2)
3	Luas Bangunan	Numerik	Luas bangunan rumah (m^2)
4	Kamar Tidur	Numerik	Jumlah kamar tidur
5	Kamar Mandi	Numerik	Jumlah kamar mandi
6	Garasi	Numerik	Kapasitas kendaraan yang dapat ditampung
7	Kota	Kategorik	Kota administrasi di DKI Jakarta
8	Kecamatan	Kategorik	Kecamatan tempat rumah berada

Deskripsi Variabel

1. Harga merupakan variabel dependen yang akan diprediksi oleh model.
2. Luas Lahan menunjukkan ukuran tanah yang dimiliki properti dalam satuan meter persegi.

3. Luas Bangunan menunjukkan total luas bangunan yang berdiri di atas lahan.
4. Kamar Tidur menggambarkan kapasitas hunian rumah.
5. Kamar Mandi menggambarkan fasilitas sanitasi yang tersedia.
6. Garasi menunjukkan kapasitas area parkir kendaraan.
7. Kota merepresentasikan wilayah administrasi seperti Jakarta Selatan, Jakarta Barat, Jakarta Timur, Jakarta Utara, dan Jakarta Pusat.
8. Kecamatan memberikan informasi lokasi yang lebih spesifik sehingga dapat menangkap perbedaan nilai properti antarwilayah.

Dataset ini memungkinkan analisis hubungan antara karakteristik fisik dan lokasi properti terhadap harga rumah, sehingga dapat digunakan untuk membangun model prediksi yang mampu menghasilkan estimasi harga secara objektif dan akurat.

2.3 Variabel Target dan Fitur

- Variabel Target (Y):

Price, harga rumah dalam satuan Rupiah. Karena distribusinya sangat right-skewed (condong ke kanan), diterapkan transformasi logaritma natural ($\log 1p$) pada target sebelum pelatihan model untuk menstabilkan varian dan mendekati distribusi normal.

- Variabel Fitur (X):

Seluruh kolom selain price dan index digunakan sebagai fitur masukan: bed_rooms, bath_rooms, carport, land_area, building_area, district, dan city.

2.4 Fitur Rekayasa (Feature Engineering)

Tiga fitur baru dibuat dari fitur yang ada untuk meningkatkan kemampuan representasi data:

building_land_ratio	building_area / land_area	Rasio efisiensi pemanfaatan lahan
total_rooms	bed_rooms + bath_rooms	Total ruang yang mencerminkan kapasitas hunian
area_per_bedroom	building_area / bed_rooms	Luas rata-rata per kamar tidur (indikator kenyamanan)

BAB III

METODOLOGI PENELITIAN

3.1 Eksplorasi Data (EDA)

3.1.1 Statistik Deskriptif

Statistik deskriptif dihitung menggunakan fungsi `df.describe()` dari library Pandas untuk semua kolom numerik (mean, median/50th percentile, std, min, max, dan quartile). Untuk kolom kategorik (district, city), digunakan `df.describe(include=object)` untuk menampilkan nilai unik dan frekuensi dominan.

Temuan statistik utama:

- Dataset memiliki 10.000 baris dengan 9 kolom. Setelah menghapus kolom index, tersisa 8 kolom bermakna.
- Harga rumah (price) memiliki nilai rata-rata sekitar Rp 4,2 miliar dengan standar deviasi yang sangat tinggi (sekitar Rp 6,8 miliar), mengindikasikan distribusi yang sangat tersebar dan right-skewed.
- Nilai median harga (Rp 2,3 miliar) jauh lebih rendah dari mean, memperkuat indikasi skewness yang signifikan.
- Dataset mencakup 253 kecamatan (district) unik di 5 kota administrasi Jakarta (Barat, Selatan, Timur, Utara, Pusat).

3.1.2 Identifikasi Kualitas Data

Pemeriksaan kualitas data dilakukan untuk mendeteksi tiga jenis masalah:

- Missing Values:
Ditemukan nilai kosong dalam jumlah sangat kecil pada kolom `land_area` dan `building_area`. Tidak ada missing value pada kolom lain.
- Duplikat:
Ditemukan sejumlah kecil baris duplikat yang kemudian dihapus menggunakan `df.drop_duplicates()`.
- Anomali:
Ditemukan data dengan nilai `price < Rp 100 juta` dan `bed_rooms = 0` atau `bath_rooms = 0`, yang dianggap tidak masuk akal secara konteks bisnis properti. Baris-baris ini dihapus.

3.1.3 Visualisasi Data

Empat jenis visualisasi dilakukan untuk memahami distribusi dan hubungan antar variabel:

- **Histogram Distribusi Harga:**
Memperlihatkan distribusi price yang sangat right-skewed dengan ekor panjang ke kanan. Mayoritas properti berada pada rentang harga Rp 1-5 miliar.
- **Boxplot Deteksi Outlier:**
Boxplot untuk land_area, building_area, bed_rooms, bath_rooms, carport, dan price menunjukkan kehadiran outlier ekstrem, terutama pada variabel area dan harga. Outlier ini mewakili properti premium/mewah yang secara valid ada di pasar.
- **Scatter Plot Luas Bangunan vs Harga**
Menunjukkan hubungan positif yang kuat antara building_area dan price — semakin luas bangunan, semakin tinggi harga. Namun terdapat varian yang besar pada setiap nilai luas, mengindikasikan pengaruh faktor lain (terutama lokasi).
- **Heatmap Korelasi Pearson:**
Menunjukkan bahwa building_area dan land_area memiliki korelasi tertinggi dengan price. Korelasi antar fitur numerik umumnya positif dan moderat.

3.2 Prapemrosesan Data (Preprocessing)

3.2.1 Pembersihan Data

Langkah-langkah pembersihan data yang dilakukan:

- Menghapus kolom index (bukan fitur bermakna).
- Menghapus baris duplikat dengan `df.drop_duplicates()`.
- Memfilter baris anomali: `price < Rp 100.000.000, bed_rooms = 0, bath_rooms = 0`.

3.2.2 Pipeline Preprocessing

Untuk menghindari data leakage, seluruh preprocessing diimplementasikan menggunakan sklearn Pipeline dan ColumnTransformer yang hanya di-fit pada data training:

Tahap	Fitur	Metode	Alasan
-------	-------	--------	--------

Imputasi Missing Value	land_area, building_area	SimpleImputer(strategy='median')	Median lebih robust terhadap outlier dibanding mean
Scaling	Semua fitur numerik	StandardScaler	Diperlukan oleh Ridge Regression; memastikan semua fitur berkontribusi proporsional
Encoding Kategorik	district, city	OneHotEncoder(handle_unknown='ignore')	Tidak ada urutan/hierarki antar nilai kategori; OHE paling tepat

3.2.3 Transformasi Target

Kolom target (price) ditransformasi menggunakan $\text{np.log}(p+1)$ (logaritma natural dari nilai+1) sebelum pelatihan. Tujuannya adalah mereduksi efek right-skewness yang ekstrem, menstabilkan varian residual, dan membuat distribusi target mendekati normal, kondisi yang lebih menguntungkan bagi sebagian besar algoritma regresi. Pada saat evaluasi, hasil prediksi dikembalikan ke skala Rupiah asli menggunakan $\text{np.expml}()$.

3.2.4 Pembagian Data

Data dibagi menjadi training set (80%) dan test set (20%) menggunakan `train_test_split` dengan `random_state=42` untuk reproducibility. Pembagian ini menghasilkan kurang lebih 8.000 data training dan 2.000 data testing.

3.3 Pemodelan (Modeling)

3.3.1 Baseline Model

Linear Regression tanpa regularisasi digunakan sebagai baseline untuk mengukur batas minimum performa yang harus dilampaui oleh model-model yang lebih kompleks.

3.3.2 Model 1: Ridge Regression

Ridge Regression adalah varian Linear Regression yang menambahkan regularisasi L2 (penalti pada besarnya koefisien). Algoritma ini dipilih karena dataset

memiliki banyak fitur kategorik hasil OHE (kolom district menghasilkan ratusan fitur biner), sehingga regularisasi membantu mencegah overfitting. Parameter $\alpha=1.0$ digunakan sebagai nilai awal.

3.3.3 Model 2: Random Forest Regressor

Random Forest adalah ensemble dari banyak Decision Tree yang dilatih pada subset acak data dan fitur (bagging). Algoritma ini sangat efektif untuk data tabular dengan hubungan non-linear dan interaksi antar fitur. Keunggulan lainnya adalah ketahanan terhadap overfitting dan kemampuan mengukur feature importance. Parameter awal: $n_estimators=100$, $random_state=42$.

3.3.4 Model 3: XGBoost Regressor

XGBoost (Extreme Gradient Boosting) adalah algoritma boosting berbasis Decision Tree yang membangun pohon secara sekuensial, di mana setiap pohon berusaha memperbaiki kesalahan pohon sebelumnya. XGBoost dikenal sebagai salah satu algoritma dengan performa terbaik untuk data tabular dalam kompetisi machine learning. Parameter awal yang digunakan disesuaikan sebelum tuning dilakukan.

3.3.5 Hyperparameter Tuning (XGBoost)

Hyperparameter tuning dilakukan pada model XGBoost menggunakan RandomizedSearchCV dengan cross-validation ($cv=3$) dan metrik $scoring='neg_mean_squared_error'$. Ruang parameter yang dieksplorasi:

Hyperparameter	Nilai yang Diuji	Fungsi
$n_estimators$	[100, 200, 300]	Jumlah pohon yang dibangun
max_depth	[4, 6, 8]	Kedalaman maksimum tiap pohon
$learning_rate$	[0.01, 0.05, 0.1, 0.2]	Tingkat penyusutan bobot koreksi
$subsample$	[0.8, 1.0]	Fraksi sampel baris per pohon
$colsample_bytree$	[0.8, 1.0]	Fraksi fitur yang digunakan per pohon

BAB IV

HASIL DAN PEMBAHASAN

4.1 Analisis Deskriptif Data dan Eksplorasi Data (EDA)

Proses awal dalam penelitian ini berfokus pada Eksplorasi Data Analitis (EDA) untuk memahami karakteristik, sebaran, korelasi, serta kualitas dari dataset harga rumah di Jakarta (*jakarta_house.csv*). Berdasarkan pemuatan awal data, sistem berhasil mengidentifikasi struktur data mentah yang mencakup fitur numerik dan kategorik.

4.1.1 Statistik Deskriptif Fitur Numerik

Statistik deskriptif dijalankan pada seluruh kolom numerik untuk melihat nilai rata-rata (*mean*), nilai tengah (*median*), standar deviasi (*std*), serta nilai minimum dan maksimum secara riil. Hasil ringkasan statistik deskriptif sebelum pembersihan data disajikan pada Tabel 4.1 berikut:

Tabel 4.1 Statistik Deskriptif Fitur Numerik Awal (N = 10.000)

Statistik	Harga Rumah (Rp)	Kamar Tidur	Kamar Mandi	Carport	Luas Tanah (m ²)	Luas Bangunan (m ²)
Jumlah Data	10	10	10	10	9.997	9.995
Rata-rata	10.040.000.000	4,25	3,52	1,58	296,61	319,96
Standar Deviasi	20.040.000.000	3,18	2,90	1,74	502,92	357,68
Nilai Minimum	1.850.000	0	0	0	1	1
Kuartil 1 / 25%	2.500.000.000	3	2	1	100	139
Median / 50%	4.500.000.000	4	3	1	177	230
Kuartil 3 / 75%	9.800.000.000	5	4	2	335	400
Nilai Maksimum	900.000.000.000	63	63	31	17.714	15.331

Based on Tabel 4.1, terlihat anomali data (*noise*) yang signifikan pada nilai minimum dan maksimum. Terdapat rumah dengan harga Rp1.850.000 yang tidak realistis untuk wilayah DKI Jakarta, serta jumlah kamar tidur dan kamar mandi mencapai 63 unit dengan luas tanah minimal hanya 1 m². Hal ini mengindikasikan adanya pencilan ekstrem atau kesalahan input data (*human error*) yang dapat mengacaukan performa model linear jika tidak dibersihkan. Selain itu, perbedaan besar antara *mean* (Rp10,04

Miliar) dan *median* (Rp4,5 Miliar) mencerminkan adanya kecondongan sebaran data yang tajam (*highly right-skewed distribution*).

4.1.2 Statistik Deskriptif Fitur Kategorik

Analisis sebaran data kategorik diterapkan pada variabel wilayah untuk memetakan frekuensi kemunculan objek properti dominan. Hasil ekstraksi disajikan pada Tabel 4.2:

Tabel 4.2 Statistik Deskriptif Fitur Kategorik

Fitur Kategorik	Jumlah Unik	Nilai Terbanyak (Modus)	Frekuensi Modus
District (Kecamatan)	253	Kelapa Gading	435
City (Kota)	5	Jakarta Selatan	3.379

Data menunjukkan bahwa Jakarta Selatan merupakan wilayah administratif dengan representasi listing rumah terbanyak (3.379 sampel), diikuti oleh Kelapa Gading sebagai kecamatan paling aktif dalam perputaran data properti (435 sampel).

4.1.3 Identifikasi Kualitas Data (Data Quality Check)

Pengecekan integritas data dilakukan secara menyeluruh mencakup identifikasi nilai kosong (*missing values*) dan baris duplikat untuk memastikan validitas analisis statistik.

- Missing Values: Ditemukan nilai kosong pada kolom `land_area` sebanyak 3 baris dan pada `building_area` sebanyak 5 baris.
- Baris Duplikat: Terdeteksi sebanyak 526 baris data yang terduplikat dari total 10.000 data awal. Keberadaan data duplikat ini berisiko memicu *data leakage* (kebocoran data) apabila lolos ke tahap pembagian *train-test set*.

4.1.4 Analisis Visualisasi Variabel Target dan Fitur

Untuk memperdalam analisis, dilakukan beberapa teknik visualisasi grafis:

1. Histogram Distribusi Target (*Price*): Plot sebaran harga properti menegaskan fenomena *right-skewed distribution*. Sebagian besar rumah mengelompok pada rentang harga di bawah Rp20 Miliar, sementara terdapat ekor panjang (*long tail*) yang menjulur ke arah nilai ratusan miliar rupiah. Guna memitigasi varians

ekstrem ini, transformasi logaritma berbasis matematis wajib diimplementasikan sebelum pemodelan dilakukan.

2. Boxplot Deteksi Outlier: Visualisasi *boxplot* pada variabel *land_area*, *building_area*, *bed_rooms*, *bath_rooms*, dan *carport* memperlihatkan sebaran titik pencilan yang masif di atas batas *upper whisker*. Hal ini memperkuat keputusan untuk melakukan pembersihan data anomali secara manual dan selektif agar model regresi tidak mengalami bias bobot.
3. Heatmap Korelasi Pearson: Matriks korelasi antarfitur numerik diekstraksi untuk melihat kekuatan hubungan linear antar-variabel terhadap harga (*price*). Nilai korelasi berkisar dari -1.00 hingga 1.00.

Tabel 4.3 Matriks Korelasi Pearson Variabel Numerik

Fitur	Price	Carport	Bath Rooms	Bed Rooms	Land Area	Building Area
Price	1,00	0,33	0,19	0,17	0,70	0,63
Carport	0,33	1,00	0,20	0,20	0,39	0,35
Bath Rooms	0,19	0,20	1,00	0,88	0,19	0,34
Bed Rooms	0,17	0,20	0,88	1,00	0,18	0,30
Land Area	0,70	0,39	0,19	0,18	1,00	0,72
Building Area	0,63	0,35	0,34	0,30	0,72	1,00

Korelasi linear terkuat terhadap *price* dimiliki oleh fitur *land_area* ($r = 0,70$) dan *building_area* ($r = 0,63$). Namun, perlu dicermati bahwa hubungan antarpemurni fitur independen seperti *bed_rooms* dan *bath_rooms* bernilai sangat tinggi yaitu 0,88. Angka tersebut menunjukkan adanya indikasi multikolinieritas tinggi yang berpotensi menurunkan stabilitas estimasi koefisien pada model *Ordinary Least Squares* (Linear Regression baseline). Sebaliknya, algoritma berbasis pohon keputusan (*tree-based ensemble*) seperti Random Forest dan XGBoost akan jauh lebih kebal terhadap kendala multikolinieritas ini.

4.2 Pembersihan Data dan Rekayasa Fitur (*Feature Engineering*)

Mendasarkan pada temuan kualitas data pada tahap EDA, dirancang sebuah alur *data cleaning* dan rekayasa fitur yang ketat untuk meningkatkan representasi pola data:

1. Eliminasi Baris Duplikat: Sebanyak 526 baris data yang teridentifikasi duplikat dihapus sepenuhnya dari sistem. Langkah ini mereduksi volume data dari 10.000 baris menjadi 9.474 baris otonom.
2. Pembersihan Anomali Fisik dan Noise Harga: Melalui filter domain pengetahuan properti, ditentukan batas logis terendah properti di Jakarta. Properti dengan harga di bawah Rp100.000.000 dieliminasi. Demikian pula, baris data dengan jumlah kamar tidur atau kamar mandi yang bernilai 0 unit dibuang karena tidak memenuhi definisi fungsional sebuah rumah tinggal standar. Setelah penyaringan *noise*, diperoleh data bersih final sebanyak 9.223 baris.
3. Konstruksi Fitur Baru (*Feature Engineering*): Untuk membantu model menangkap karakteristik spasial dan rasio utilitas bangunan, dibentuk tiga fitur baru:
 - `building_land_ratio`: Rasio luas bangunan dibagi luas tanah, merepresentasikan kepadatan pemanfaatan lahan properti.
 - `total_rooms`: Akumulasi total kamar tidur dan kamar mandi (`bed_rooms` + `bath_rooms`).
 - `area_per_bedroom`: Luas bangunan dibagi jumlah kamar tidur, sebagai indikator kenyamanan dimensi interior

Pemisahan Data dan Transformasi Target

Matriks fitur (X) dipisahkan dari variabel target (Y yaitu `price`). Untuk mengatasi kendala sebaran target yang condong ke kanan (*right-skewed*), diimplementasikan fungsi transformasi logaritma natural $\text{np.log1p}(y)$. Transformasi ini bertujuan menstabilkan varians sisaan (*homoskedastisitas*) sepanjang garis regresi. Selanjutnya, data dibagi menggunakan proporsi 80% untuk Train Set (7.378 sampel) dan 20% untuk Test Set (1.845 sampel) dengan penguncian parameter `random_state = 42` demi aspek replikabilitas eksperimen.

4.3 Desain Arsitektur Preprocessing Pipeline

Guna menghindari terjadinya *data leakage* (kebocoran informasi dari data uji ke data latih), seluruh tahapan transformasi digabungkan ke dalam sebuah *Super Pipeline* menggunakan Scikit-Learn `ColumnTransformer`. Struktur pembagian taksonomi fitur dirancang sebagai berikut:

1. Sub-Pipeline Fitur Numerik: Ditujukan untuk 8 variabel numerik. Berkas missing values diimputasi menggunakan nilai Median melalui komponen `SimpleImputer` untuk menjaga kekebalan terhadap pencilan. Standardisasi skala dilakukan menggunakan

StandardScaler agar seluruh fitur memiliki rata-rata nol ($\mu = 0$) dan varians unit ($\sigma = 1$).

2. Sub-Pipeline Fitur Kategorik: Diterapkan pada fitur district dan city. Nilai kosong diisi menggunakan nilai yang paling sering muncul (Modus/Most Frequent). Selanjutnya, dilakukan transformasi biner menggunakan OneHotEncoder dengan konfigurasi `handle_unknown='ignore'` guna mengantisipasi munculnya nama kecamatan baru pada data uji yang tidak terekam pada data latih.

Ekssekusi taktik *fit_transform* pada data latih sukses memetakan dimensi fitur dari yang semula hanya 10 kolom menjadi matriks spasial renggang (*sparse matrix*) berukuran (7.378, 259) akibat ekspansi kolom kategori hasil *one-hot encoding*. Sementara itu, data uji hanya dikenakan perintah *transform* murni untuk menjamin objektivitas pengujian.

4.4 Evaluasi Performa Model Baseline dan Pembanding (*Before Tuning*)

Eksperimen pemodelan dilakukan dengan membandingkan performa empat algoritma dengan karakteristik matematis yang berbeda: *Linear Regression* (sebagai baseline), *Ridge Regression* (regularisasi L2), *Random Forest* (tree ensemble), dan *XGBoost* (gradient boosting). Pengujian performa dinilai secara objektif menggunakan data uji (*test set*), di mana seluruh prediksi sisaan skala logaritma dikembalikan ke skala Rupiah asli menggunakan fungsi inversi eksponensial `np.expml()`. Metrik evaluasi yang digunakan meliputi *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan *R-squared* (R^2).

Tabel 4.4 Rangkuman Performa Awal Model Komparatif (Sebelum Tuning)

No	Model Algoritma	MAE (Rp)	RMSE (Rp)	R^2 Score
1	Baseline — Linear Regression	4.873.481.000	33.062.210.000	0,73
2	Ridge Regression $\alpha = 1,0$	4.920.624.000	34.174.820.000	0,74
3	Random Forest Regressor	3.042.631.000	9.982.091.000	0,88
4	XGBoost Regressor	2.745.802.000	8.848.488.000	0,89

Berdasarkan Tabel 4.4, model linear (Linear & Ridge Regression) menunjukkan performa terendah dengan R^2 hanya berkisar di angka 0,73 - 0,74 dan nilai galat RMSE yang sangat besar (mencapai lebih dari Rp33 Miliar). Hal ini membuktikan bahwa hubungan antara karakteristik fisik properti di Jakarta terhadap harga jualnya bersifat non-linear kompleks, yang tidak mampu ditangkap secara optimal oleh fungsi garis lurus regresi parametrik. Di sisi lain, model non-parametrik berbasis *ensemble learning* mencatat lonjakan performa

yang masif. Random Forest meraih R^2 sebesar 0,88. Performa terbaik sebelum tuning dipimpin oleh XGBoost Regressor dengan nilai MAE terkecil sebesar Rp2.745.802.000, RMSE Rp8.848.488.000, serta akurasi varians (R^2) mencapai 0,89. Algoritma *gradient boosting* terbukti unggul karena kemampuannya meminimalkan eror secara iteratif melalui koreksi bobot *loss function* dari pohon-pohon keputusan sebelumnya. Maka dari itu, XGBoost dipilih sebagai kandidat tunggal untuk melangkah ke tahap optimasi *hyperparameter*.

4.5 Optimasi Model via *Hyperparameter Tuning*

Untuk mendongkrak performa XGBoost menuju tingkat akurasi tertinggi, dilakukan proses penyetelan parameter menggunakan metode *RandomizedSearchCV* dikombinasikan dengan *3-Fold Cross Validation*. Ruang kombinasi parameter (*hyperparameter space*) dirancang secara variatif mencakup fleksibilitas struktur pohon dan laju pembelajaran:

- `n_estimators`: [100, 200, 300] (kuantitas pohon keputusan)
- `max_depth`: [4, 6, 8] (kedalaman maksimum struktur pohon)
- `learning_rate`: [0.01, 0.05, 0.1, 0.2] (bobot penyusutan koreksi / eta)
- `subsample`: [0.8, 1.0] (rasio baris sampel per pohon)
- `colsample_bytree`: [0.8, 1.0] (rasio fitur kolom per pohon)

Melalui penjelajahan acak sebanyak 5 iterasi kombinasi, terpilihlah arsitektur estimator terbaik (*best estimator*) yang menghasilkan performa pengujian akhir sebagai berikut:

Tabel 4.5 Perbandingan Hasil Sebelum vs Setelah *Hyperparameter Tuning*

Metrik Evaluasi	Sebelum Tuning (XGBoost)	Setelah Tuning (XGBoost Tuned)	Peningkatan Efisiensi
MAE (Rupiah)	2.745.802.000	2.621.293.349,19	Penurunan error $\approx$ Rp124,5 juta
RMSE (Rupiah)	8.848.488.000	8.304.090.781,79	Penurunan error $\approx$ Rp544,3 juta
R^2 Score	0,8900	0,9041	Peningkatan akurasi $\approx$ 1,41%

Proses *hyperparameter tuning* memberikan dampak positif yang signifikan secara komersial maupun statistik. Nilai rata-rata deviasi prediksi (MAE) berhasil ditekan hingga menyentuh angka Rp2,62 Miliar. Nilai RMSE yang sensitif terhadap pencilan besar juga mengalami penurunan drastis sebesar Rp544,3 Juta, yang menandakan model semakin

stabil dalam memprediksi rumah-rumah di kelas harga premium. Lebih jauh, perolehan nilai R^2 sebesar 0,9041 menegaskan bahwa model XGBoost hasil optimasi ini mampu menjelaskan 90,41% variabilitas perubahan harga rumah di DKI Jakarta berdasarkan fitur-fitur yang dimiliki, sedangkan sisanya sebesar 9,59% dipengaruhi oleh faktor luar yang tidak diteliti (seperti kondisi makroekonomi, kedekatan fasilitas umum spesifik, atau faktor emosional pembeli).

4.6 Analisis Sisaan (*Residual Analysis*) dan Grafik Prediksi

Evaluasi kelayakan model secara mendalam dibuktikan melalui analisis sisaan grafis yang membandingkan nilai aktual dengan hasil taksiran model.

1. Plot Prediksi vs Aktual (Skala Rupiah Asli): Visualisasi ini membatasi rentang harga dominan hingga Rp20 Miliar agar persebaran titik data dapat diamati secara jelas. Hasil plot menunjukkan titik-titik koordinat teal mengelompok secara rapat di sekitar garis diagonal merah putus-putus yang melambangkan garis ideal regresi sempurna ($Y_{aktual} = Y_{prediksi}$). Hal ini membuktikan akurasi model yang tinggi pada klaster harga rumah dominan di Jakarta.
2. Plot Analisis Residual (Residuals vs Predicted dalam Skala Log): Analisis galat (*error*) dilakukan pada skala logaritma agar memenuhi asumsi sebaran normal. Berdasarkan plot sebaran eror, titik-titik ungu menyebar secara acak, konstan, dan seimbang di sekitar garis horizontal ideal eror = 0. Tidak terbentuk pola matematis tertentu (seperti pola corong atau melengkung) yang mengindikasikan bahwa model telah berhasil mengekstrak seluruh informasi linear maupun non-linear dari fitur properti, serta terbebas dari gejala serius heteroskedastisitas.

4.7 Analisis Kontribusi Fitur (*Feature Importance*)

Langkah akhir dari pembahasan ini adalah membongkar aspek transparansi model (*black box*) menggunakan analisis *Feature Importance Score* berbasis struktur pohon dari model XGBoost terbaik. Dari total 259 dimensi fitur yang masuk ke dalam sistem, diekstraksi 10 fitur teratas yang memegang kendali paling dominan dalam penentuan estimasi nilai jual rumah di Jakarta.

Tabel 4.6 Daftar 10 Fitur Paling Berpengaruh Terhadap Harga Rumah

Peringkat	Nama Variabel Fitur	Skor Kepentingan (Importance Score)	Tipe Variabel
1	land_area (Luas Tanah)	0,1271	Numerik Asli

2	city_Jakarta Timur	0,0636	Kategorik (Kota)
3	building_area (Luas Bangunan)	0,0501	Numerik Asli
4	district_Kebayoran Baru	0,0478	Kategorik (Kecamatan)
5	city_Jakarta Selatan	0,0415	Kategorik (Kota)
6	district_Menteng	0,0395	Kategorik (Kecamatan)
7	district_Pondok Indah	0,0330	Kategorik (Kecamatan)
8	city_Jakarta Pusat	0,0270	Kategorik (Kota)
9	district_Pantai Indah Kapuk	0,0210	Kategorik (Kecamatan)
10	city_Jakarta Barat	0,0200	Kategorik (Kota)

Interpretasi:

1. Dominasi Dimensi Fisik Properti (land_area & building_area): Variabel land_area menempati urutan pertama sebagai pendorong harga utama dengan nilai kontribusi tertinggi sebesar 0,1271. Hal ini selaras dengan hukum ekonomi properti perkotaan, di mana ketersediaan tanah di ibukota bersifat tetap (*fixed supply*) sementara permintaan terus meroket, menjadikan luas tanah sebagai komoditas termahal. Selanjutnya, building_area menempati posisi ketiga dengan skor 0,0501, menegaskan bahwa volume bangunan fisik berkontribusi linear terhadap penambahan nilai valuasi rumah.
2. Pengaruh Faktor Geografis Administratif Spasial: Temuan menarik terlihat pada peringkat ke-2, di mana fitur city_Jakarta Timur memiliki *importance score* sebesar 0,0636. Wilayah Jakarta Timur bertindak sebagai pembeda segmentasi harga yang krusial bagi model, kemungkinan karena karakteristik wilayah tersebut yang memiliki variabilitas harga yang kontras dibandingkan wilayah elit lainnya. Selanjutnya, variabel wilayah premium seperti city_Jakarta Selatan (0,0415) ikut mengambil peran dominan.
3. Spesifikasi Efek Premium Lokasi Mikro (*Elite District Effect*): Model secara cerdas mampu mengenali nilai prestise dari lokasi mikro (Kecamatan). Munculnya kecamatan elit seperti district_Kebayoran Baru (0,0478), district_Menteng ($\approx 0,0395$), district_Pondok Indah ($\approx 0,0330$), dan district_Pantai Indah Kapuk ($\approx 0,0210$) membuktikan bahwa model XGBoost mampu menangkap parameter "gengsi/prestise lingkungan". Properti yang terletak di dalam wilayah biner tersebut secara otomatis akan mendapat penyesuaian bobot harga ke atas oleh algoritma, karena area-area ini secara historis dikenal sebagai kawasan hunian mewah kelas atas di Jakarta.

Sebaliknya, ratusan kecamatan lain (seperti *Villa Meruya*, *Veteran*, *Utan Kayu*, *Tubagus Angke*, dll.) memiliki nilai kepentingan 0,0000, yang mengindikasikan bahwa keberadaan properti di area-area tersebut memberikan dampak netral atau standar pada perhitungan harga dasar model.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa metode ensemble learning mampu memberikan performa yang sangat baik dalam mengestimasi harga properti residensial di wilayah DKI Jakarta. Proses eksplorasi data menunjukkan bahwa dataset memiliki distribusi harga yang sangat tidak simetris (right-skewed), mengandung outlier ekstrem, serta dipengaruhi oleh berbagai karakteristik fisik dan lokasi properti.

Tahap preprocessing yang meliputi pembersihan data, imputasi missing value, transformasi logaritmik pada variabel target, serta penerapan pipeline komputasi berhasil meningkatkan kualitas data yang digunakan dalam proses pemodelan. Selain itu, rekayasa fitur berupa building land ratio, total rooms, dan area per bedroom mampu menambahkan informasi yang relevan dalam menjelaskan variasi harga rumah.

Perbandingan performa model menunjukkan bahwa algoritma ensemble learning berbasis pohon keputusan memiliki kemampuan prediksi yang lebih baik dibandingkan model regresi linear. Model terbaik diperoleh dari XGBoost setelah proses hyperparameter tuning dengan nilai MAE sebesar Rp2,62 miliar, RMSE sebesar Rp8,30 miliar, dan R^2 sebesar 0,9041. Hasil tersebut menunjukkan bahwa model mampu menjelaskan sekitar 90,41% variasi harga rumah pada dataset.

Analisis feature importance menunjukkan bahwa luas lahan, luas bangunan, serta faktor lokasi merupakan variabel yang paling berpengaruh dalam menentukan harga properti residensial di DKI Jakarta. Dengan demikian, pendekatan ensemble learning berbasis pipeline komputasi terbukti efektif dan layak digunakan sebagai sistem estimasi harga properti yang objektif, cepat, dan akurat.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, pengembangan model prediksi harga properti di masa mendatang dapat dilakukan dengan menambahkan variabel-variabel yang lebih beragam, seperti jarak ke pusat bisnis, akses transportasi umum, fasilitas pendidikan, rumah sakit, serta pusat perbelanjaan. Variabel-variabel tersebut diperkirakan dapat meningkatkan kemampuan model dalam menangkap pengaruh faktor spasial yang sangat berperan terhadap pembentukan harga properti di wilayah perkotaan.

Selain itu, penelitian selanjutnya disarankan menggunakan dataset dengan cakupan wilayah yang lebih luas, seperti Jabodetabek atau kota-kota besar lainnya di Indonesia, sehingga model yang dihasilkan memiliki kemampuan generalisasi yang lebih baik dan dapat diterapkan pada berbagai kondisi pasar properti. Penggunaan data yang lebih mutakhir dan jumlah observasi yang lebih besar juga berpotensi meningkatkan akurasi model.

Dari sisi pemodelan, penelitian berikutnya dapat membandingkan performa algoritma lain yang juga populer pada data tabular, seperti LightGBM, CatBoost, maupun metode Stacking Ensemble yang menggabungkan beberapa model sekaligus. Selain itu, proses optimasi hyperparameter dapat dilakukan dengan metode yang lebih komprehensif, seperti Grid Search atau Bayesian Optimization, untuk memperoleh konfigurasi model yang lebih optimal.

Terakhir, hasil penelitian ini dapat dikembangkan menjadi sebuah aplikasi berbasis web atau sistem pendukung keputusan yang mampu memberikan estimasi harga properti secara otomatis. Implementasi tersebut akan memberikan manfaat praktis bagi masyarakat, agen properti, investor, maupun lembaga keuangan dalam proses penentuan nilai properti secara lebih cepat, objektif, dan efisien.

LAMPIRAN

Link Github : <https://github.com/Rellamm/Project-ML-Grup-E>

Link Python : <https://colab.research.google.com/drive/1Zgj1BUptKpSDhi6KcjC35Y6G-0E2PIpc?usp=sharing>

Link AI : <https://share.gemini.google/NWtvXiefE1Wq>