



IMPLEMENTASI METODE ENSEMBLE LEARNING UNTUK PREDIKSI HARGA PROPERTI RESIDENSIAL DI WILAYAH DKI JAKARTA



Kelompok E

- 
- **Abdurrahman Yusuf (K1D024058)**
 - **Salsabella Setya Choerunissa (K1D024060)**
 - **Eriani Hardianti (K1D024062)**
 - **Rey El Islamay (K1D024070)**
- 



Latar Belakang



Sebagai episentrum ekonomi, DKI Jakarta menghadapi ketidakseimbangan akut antara urbanisasi yang masif (demand) dan keterbatasan lahan permanen (fixed supply), sehingga memicu fluktuasi serta dispersi harga properti residensial yang sangat ekstrem dan non-linear. Di sisi lain, metode penaksiran harga konvensional masih bersifat manual, rentan bias subjektif, dan memiliki keterbatasan sampel. Padahal, nilai ekonomi sebuah rumah terbentuk dari interaksi multidimensional yang kompleks antara atribut fisik dan lokasi spasial, sehingga diperlukan pendekatan pemodelan objektif yang mampu menangkap pola tersebut secara cepat dan akurat.






Urgensi & Pentingnya Penelitian

1. Mitigasi Asimetri Informasi (Information Asymmetry) :
Menyediakan acuan harga yang objektif dan transparan untuk mencegah kerugian akibat overpricing atau underpricing bagi penjual dan pembeli.
2. Percepatan Manajemen Risiko Kredit Lembaga Keuangan
Perbankan : Mempercepat proses penilaian agunan KPR secara otomatis, menghemat biaya operasional, dan memitigasi risiko kredit macet (NPL).
3. Penerapan Teori Ekonomi Spasial dan Kepadatan Lahan :
Membuktikan pengaruh kepadatan bangunan dan tata ruang internal terhadap nilai ekonomi rumah di kawasan padat.
4. Kebutuhan Solusi Terhadap Distribusi Data Asimetris (Skewed Data) : Mengatasi bias akibat data harga rumah mewah yang ekstrem menggunakan algoritma berbasis pohon (tree-based).





Definisi Masalah Machine Learning & Sumber Data



penelitian ini mendefinisikan estimasi harga properti residensial sebagai sebuah masalah regresi (regression problem) di bawah paradigma pembelajaran terbimbing (supervised learning). Hal ini dikarenakan variabel target yang ingin diprediksi, yaitu harga jual rumah, merupakan data numerik kontinu (skala rasio) dalam satuan mata uang Rupiah nominal. Secara matematis, tujuan utama dari pemodelan ini adalah mengonstruksi sebuah fungsi pendekatan objektif yang mampu memetakan karakteristik fisik internal bangunan maupun komponen spasial lokasi ke dalam ruang estimasi nilai pasar sekunder secara akurat dengan meminimalkan nilai loss function (fungsi kerugian) dari algoritma yang digunakan.

Data yang digunakan dalam penelitian ini merupakan data sekunder berupa "Jakarta House Price Dataset" yang diperoleh melalui repositori publik Kaggle. Basis data tersebut dihimpun secara langsung menggunakan teknik penambangan data web (web scraping) terhadap iklan penawaran aktif di portal properti terkemuka, yaitu Rumah123.com. Dataset ini merekam kondisi riil transaksi dan penawaran di pasar sekunder properti residensial dengan total observasi awal mencapai 10.000 baris data yang mencakup variasi sebaran wilayah di 5 kota administrasi dan 253 kecamatan di seluruh area DKI Jakarta, sehingga mampu merepresentasikan dispersi dan volatilitas harga properti di wilayah megapolitan secara komprehensif.

No	Nama Variabel	Tipe Data	Keterangan
1	Harga	Numerik	Harga jual rumah (variabel target)
2	Luas Lahan	Numerik	Luas tanah rumah
3	Luas Bangunan	Numerik	Luas bangunan rumah
4	Kamar Tidur	Numerik	Jumlah kamar tidur
5	Kamar Mandi	Numerik	Jumlah kamar mandi
6	Garasi	Numerik	Kapasitas kendaraan yang dapat
7	Kota	Kategorik	Kota administrasi di DKI Jakarta
8	Kecamatan	Kategorik	Kecamatan tempat rumah berada

Diciptakan 3 variabel baru berdasarkan domain ekonomi properti untuk mengekstrak pola non-linear:

building_land_ratio	building_area / land_area	Rasio efisiensi pemanfaatan lahan
total_rooms	bed_rooms + bath_rooms	Total ruang yang mencerminkan kapasitas hunian
area_per_bedroom	building_area / bed_rooms	Luas rata-rata per kamar tidur (indikator kenyamanan)



Data * Dictionary & Feature Engineering



Eksplorasi Data Analitis (EDA)


Variabel	Rata-rata (Mean)	Nilai Tengah (Median)	Nilai Minimum	Nilai Maksimum	Status & Tindakan Preprocessing
price (Rp)	10,04 Miliar	4,50 Miliar	1,85 Juta	900 Miliar	Highly right-skewed → Transformasi log1p
land_area (m ²)	296.61	177	1	17.714,00	Imputasi median & filter noise (<100 m ² / anomali)
building_area (m ²)	319.96	23,000	1	15.331,00	Imputasi median & pembersihan data kosong
kamar (tidur/mandi)	4,25 / 3,52	4,00 / 3,00	0	63	Filter nilai 0 & eliminasi outlier ekstrem (>60 unit)

- Distribusi Highly Right-Skewed: Nilai mean harga rumah (Rp10,04 M) jauh lebih tinggi dari median (Rp4,5 M). Ketimpangan ekstrem ini diatasi dengan transformasi logaritma `np.log1p` guna menstabilkan varians sisaan model.
- Anomali & Noise Data: Ditemukan ketidakwajaran data mentah, seperti harga rumah Rp1,85 juta, luas tanah 1 m², jumlah kamar hingga 63 unit, serta 526 data duplikat. Seluruh noise ini dieleminasi pada tahap data cleaning agar model terbebas dari bias bobot.
- Multikolinieritas Tinggi: Terdeteksi korelasi linear ekstrem sebesar 0,88 antara jumlah kamar tidur dan kamar mandi. Karena kondisi ini merusak stabilitas model regresi linear standar, temuan ini menjadi justifikasi kuat bagi kami untuk menggunakan algoritma Non-Parametrik Tree-Based Ensemble (Random Forest dan XGBoost) yang terbukti jauh lebih kebal terhadap masalah multikolinieritas.



PRAPEMROSESAN DATA & REKAYASA FITUR (DATA PREPROCESSING)

Tahapan Preprocessing	Deskripsi & Formula Matematis	Log Volume Data	Justifikasi Ilmiah & Insight Sidang
1. Data Mentah Awal	Dataset awal: <i>jakarta_house.csv</i> (data belum diproses)	10.000 baris	Kondisi awal data digunakan sebagai baseline untuk evaluasi kualitas dataset sebelum dilakukan proses validasi dan pembersihan data.
2. Data Cleaning & Filtering	Eliminasi data duplikat + filter noise: $\text{price} \geq \text{Rp}100 \text{ juta}$, $\text{bed_rooms} > 0$, $\text{bath_rooms} > 0$	9.223 baris (setelah filtering)	Penghapusan data duplikat untuk mencegah data leakage. Filter nilai ekstrem dan tidak valid (misalnya harga sangat rendah dan rumah tanpa kamar) meningkatkan reliabilitas model.
3. Feature Engineering	- $\text{building_land_ratio} = \text{building_area} / \text{land_area}$ - $\text{total_rooms} = \text{bed_rooms} + \text{bath_rooms}$ - $\text{area_per_bedroom} = \text{building_area} / \text{bed_rooms}$	9.223 baris (13 fitur)	Pembuatan fitur turunan bertujuan menangkap hubungan struktural properti seperti kepadatan lahan dan efisiensi ruang, sehingga meningkatkan daya prediksi model.
4. Data Splitting	Train-test split = 80:20, random_state = 42	Train: 7.378 Test: 1.845	Pembagian data dilakukan untuk memastikan evaluasi model yang objektif pada data yang tidak pernah dilihat sebelumnya serta menjaga replikasi eksperimen.
5. Arsitektur Pipeline & Encoding	Numerik: Median Imputer + StandardScaler Kategorik: Most Frequent Imputer + OneHotEncoder	(7.378, 259 fitur)	Imputasi median menjaga robust terhadap outlier, sedangkan One-Hot Encoding mengubah fitur spasial menjadi representasi numerik untuk menangkap pengaruh lokasi secara detail.






Prapemrosesan Data & Desain Pipeline

Seluruh transformasi digabung dalam satu Super Pipeline (Scikit-Learn ColumnTransformer) agar tidak terjadi data leakage fit hanya pada data training.

- Sub-pipeline numerik (8 variabel): imputasi missing value dengan median (SimpleImputer) → StandardScaler ($\mu=0$, $\sigma=1$). Nilai yang kosong diisi dengan median (nilai tengah, lebih tahan terhadap data ekstrem), lalu semua angka diseragamkan skalanya (standardisasi) agar tidak ada variabel yang "mendominasi" hanya karena satuannya lebih besar.
- Sub-pipeline kategorik (district, city): imputasi modus → OneHotEncoder (handle_unknown='ignore') agar tahan terhadap kecamatan baru di data uji. Nilai kosong diisi dengan kategori yang paling sering muncul, lalu diubah menjadi format angka biner (0/1) yang bisa dibaca model termasuk antisipasi kalau muncul nama kecamatan baru yang belum pernah dilihat model.
- Pembagian data: 80% Train (7.378 sampel) : 20% Test (1.845 sampel), random_state=42.
- Hasil fit_transform mengubah 10 kolom awal menjadi sparse matrix berdimensi (7.378 × 259) akibat ekspansi one-hot encoding.

EVALUASI & PERBANDINGAN MODEL AWAL (BASELINE MODEL)

No	Model Algoritma	MAE (Rupiah)	RMSE (Rupiah)	R ² Score	Status Model
1	Baseline (Linear Regression)	4.873.481.000	33.062.210.000	73	Underfitting / Gagal
2	Ridge Regression (α = 1.0)	4.920.624.000	34.174.820.000	74	Underfitting
3	Random Forest (Tree-Based)	3.042.631.000	9.982.091.000	88	Performa Kuat
4	XGBoost Regressor (Gradient Boosting)	2.745.802.000	8.848.488.000	89	Terbaik (Lolos Seleksi)



Grafik batang R² Score ini menunjukkan kegagalan model linear parametrik (Linear & Ridge Regression di kisaran 0,73–0,74) dalam memetakan harga rumah di Jakarta yang polanya terbukti bersifat non-linear kompleks. Sebaliknya, model non-parametrik berbasis pohon (Random Forest dan XGBoost) bekerja jauh lebih superior karena mampu menangkap interaksi rumit antarfitur fisik dan lokasi mikro secara hierarkis. Hasil eksperimen ini memberikan justifikasi empiris bagi kami untuk memilih XGBoost Regressor sebagai model terbaik dengan akurasi awal tertinggi (0,89) untuk diloloskan ke tahap optimasi hyperparameter.



Optimasi Model & Analisis Hasil Akhir (Hyperparameter Tuning) *

1. Menentukan ruang kombinasi parameter yang akan dicari (Hyperparameter Space)

```
ruang_param_xgb = {
    'n_estimators': [100, 200, 300],      # Jumlah pohon keputusan yang dibangun
    'max_depth': [4, 6, 8],               # Kedalaman maksimum setiap pohon
    'learning_rate': [0.01, 0.05, 0.1, 0.2], # Tingkat penyusutan bobot koreksi (eta)
    'subsample': [0.8, 1.0],              # Rasio sampel baris untuk setiap pohon
    'colsample_bytree': [0.8, 1.0]        # Rasio sampel kolom (fitur) untuk setiap pohon
}
```

Interpretasi :

Optimasi menggunakan RandomizedSearchCV berhasil mendongkrak akurasi final (R^2 Score) XGBoost menjadi 0,9041 (90,41%). Secara komersial, penyetelan parameter ini sukses memangkas rata-rata eror prediksi (MAE) sebesar Rp124,5 Juta serta mereduksi eror ekstrem (RMSE) hingga Rp544,3 Juta. Hasil ini membuktikan secara valid bahwa model final menjadi jauh lebih akurat dan stabil, terutama untuk menaksir properti di kelas harga premium.


3. Perbandingan model sebelum dan sesudah Tuning

Metrik Evaluasi	Sebelum Tuning (XGBoost)	Setelah Tuning (XGBoost Tuned)	Peningkatan Efisiensi (Dampak Nyata)
MAE (Mean Absolute Error)	Rp2.745.802.000,00	Rp2.621.293.349,19	Penurunan rata-rata error $\approx$ Rp124,5 juta
RMSE (Root Mean Squared Error)	Rp8.848.488.000,00	Rp8.304.090.781,79	Penurunan error ekstrem $\approx$ Rp544,3 juta
R^2 Score (Akurasi Varians)	0,8900 (89,00%)	0,9041 (90,41%)	Peningkatan akurasi $\approx$ 1,41%

2. Inisialisasi RandomizedSearchCV khusus untuk XGBoost

```
pencarian_param_xgb = RandomizedSearchCV(
    estimator=XGBRegressor(random_state=42, n_jobs=-1),
    param_distributions=ruang_param_xgb,
    n_iter=5,           # Mencoba 5 kombinasi parameter secara acak
    cv=3,               # 3-Fold Cross Validation (Validasi Silang)
    scoring='r2',       # Metrik optimasi berdasarkan R-squared
    random_state=42,    # Mengunci nilai keacakan pencarian agar eksperimen ini bersifat replikatif
    n_jobs=-1           # Menginstruksikan sistem untuk menjalankan proses pencarian secara paralel
)                       # menggunakan seluruh performa komputasi prosesor yang tersedia
```

Analisis Sisaan & Validasi Model (Residual Analysis)



Dua visualisasi digunakan untuk menguji kelayakan model XGBoost tuned:

- Plot Prediksi vs Aktual (skala Rupiah, dibatasi $\leq$ Rp20 M agar terbaca): titik-titik mengelompok rapat di sekitar garis diagonal ideal ($Y_{\text{aktual}} = Y_{\text{prediksi}}$) $\rightarrow$ akurasi tinggi pada klaster harga dominan.
- Plot Residual vs Predicted (skala log): error menyebar acak, konstan, dan seimbang di sekitar garis nol, tanpa pola corong/lengkung $\rightarrow$ model bebas dari heteroskedastisitas serius dan sudah menangkap pola linear maupun non-linear dari fitur.

Analisis Kontribusi Fitur (Feature Importance)

Peringkat	Fitur	Importance Score
1	land_area	1,271
2	city_Jakarta Timur	636
3	building_area	501
4	district_Kebayoran Baru	478
5	city_Jakarta Selatan	415
6	district_Menteng	395
7	district_Pondok Indah	330
8	city_Jakarta Pusat	270
9	district_Pantai Indah	210
10	city_Jakarta Barat	200

Luas tanah dan luas bangunan menjadi faktor paling dominan dalam menentukan harga rumah, karena lahan di Jakarta yang terbatas (fixed supply) membuatnya menjadi komoditas termahal. Selain itu, lokasi juga sangat berpengaruh wilayah seperti Jakarta Selatan dan Jakarta Timur menjadi pembeda harga antarwilayah, sementara kecamatan elit seperti Kebayoran Baru, Menteng, dan Pondok Indah menunjukkan "efek prestise lokasi" yang mendorong harga properti lebih tinggi.

Kesimpulan

Berdasarkan hasil penelitian, metode ensemble learning terbukti efektif dalam mengestimasi harga properti residensial di DKI Jakarta. Tahap preprocessing dan rekayasa fitur berhasil meningkatkan kualitas data serta performa model. Model terbaik yang diperoleh adalah XGBoost dengan nilai MAE sebesar Rp2,62 miliar, RMSE sebesar Rp8,30 miliar, dan R^2 sebesar 0,9041, yang menunjukkan kemampuan model dalam menjelaskan 90,41% variasi harga rumah. Analisis feature importance menunjukkan bahwa luas lahan, luas bangunan, dan lokasi merupakan faktor yang paling berpengaruh terhadap harga properti. Dengan demikian, pendekatan ini layak digunakan sebagai sistem estimasi harga properti yang akurat, objektif, dan efisien.

Saran

Untuk pengembangan penelitian di masa mendatang, disarankan agar model dapat diperkaya dengan menambahkan variabel eksternal spasial yang lebih komprehensif, seperti aksesibilitas transportasi umum (stasiun MRT/LRT), kedekatan pintu tol, serta jarak ke pusat bisnis (CBD) dan fasilitas publik guna meningkatkan daya tangkap faktor lokasi perkotaan. Selain itu, penelitian selanjutnya direkomendasikan untuk memperluas cakupan wilayah data hingga skala megapolitan Jabodetabek dengan jumlah observasi yang lebih mutakhir agar meningkatkan kemampuan generalisasi model.



TERIMA KASIH

